Chapter 02
Modeling

Introduction

- IR systems usually adopt index terms to process queries
- Index term:
  - a keyword or group of selected words
  - any word (more general)
- Stemming might be used:
  - connect: connecting, connection, connections
- An **inverted file** is built for the chosen index terms

Introduction

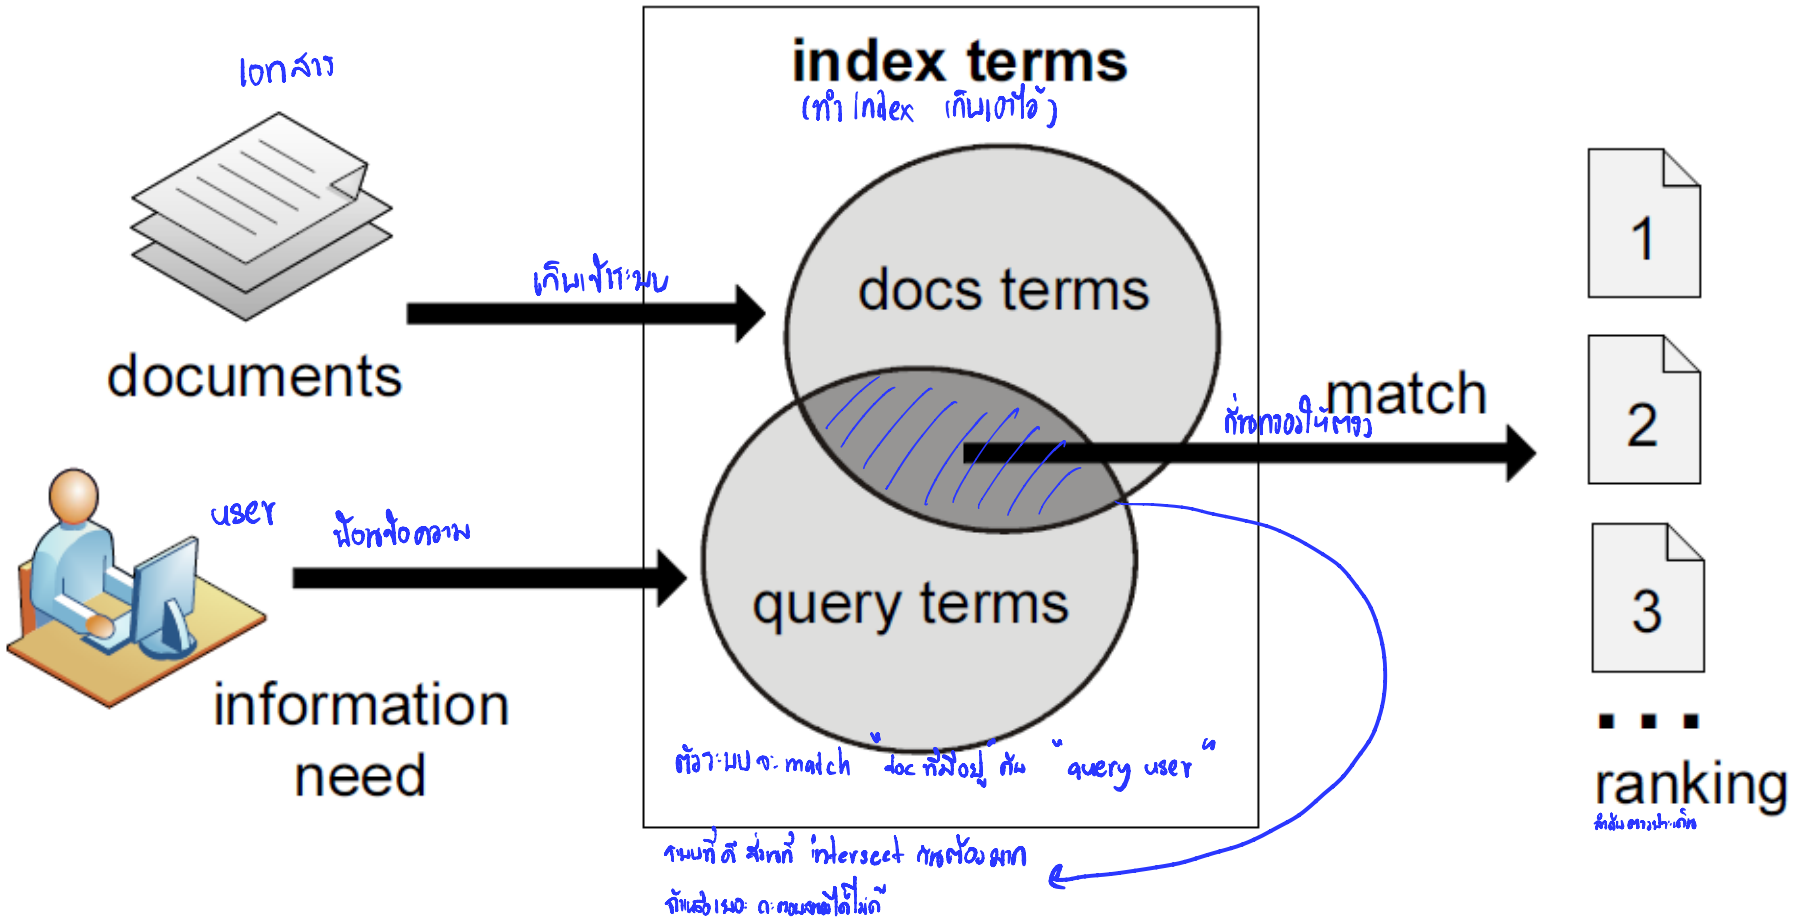

Introduction

- A ***ranking*** is an ordering of the documents retrieved that (hopefully) reflects the relevance of the documents to the user query
- A ranking is based on fundamental premisses regarding the notion of relevance, such as:
  - common sets of index terms — **Tree**, **Tree**
  - sharing of weighted terms — **Tree**, **Plant**
  - likelihood of relevance — **Tree**, **Agriculture**
- Each set of premisses leads to a distinct *IR model*

IR Models

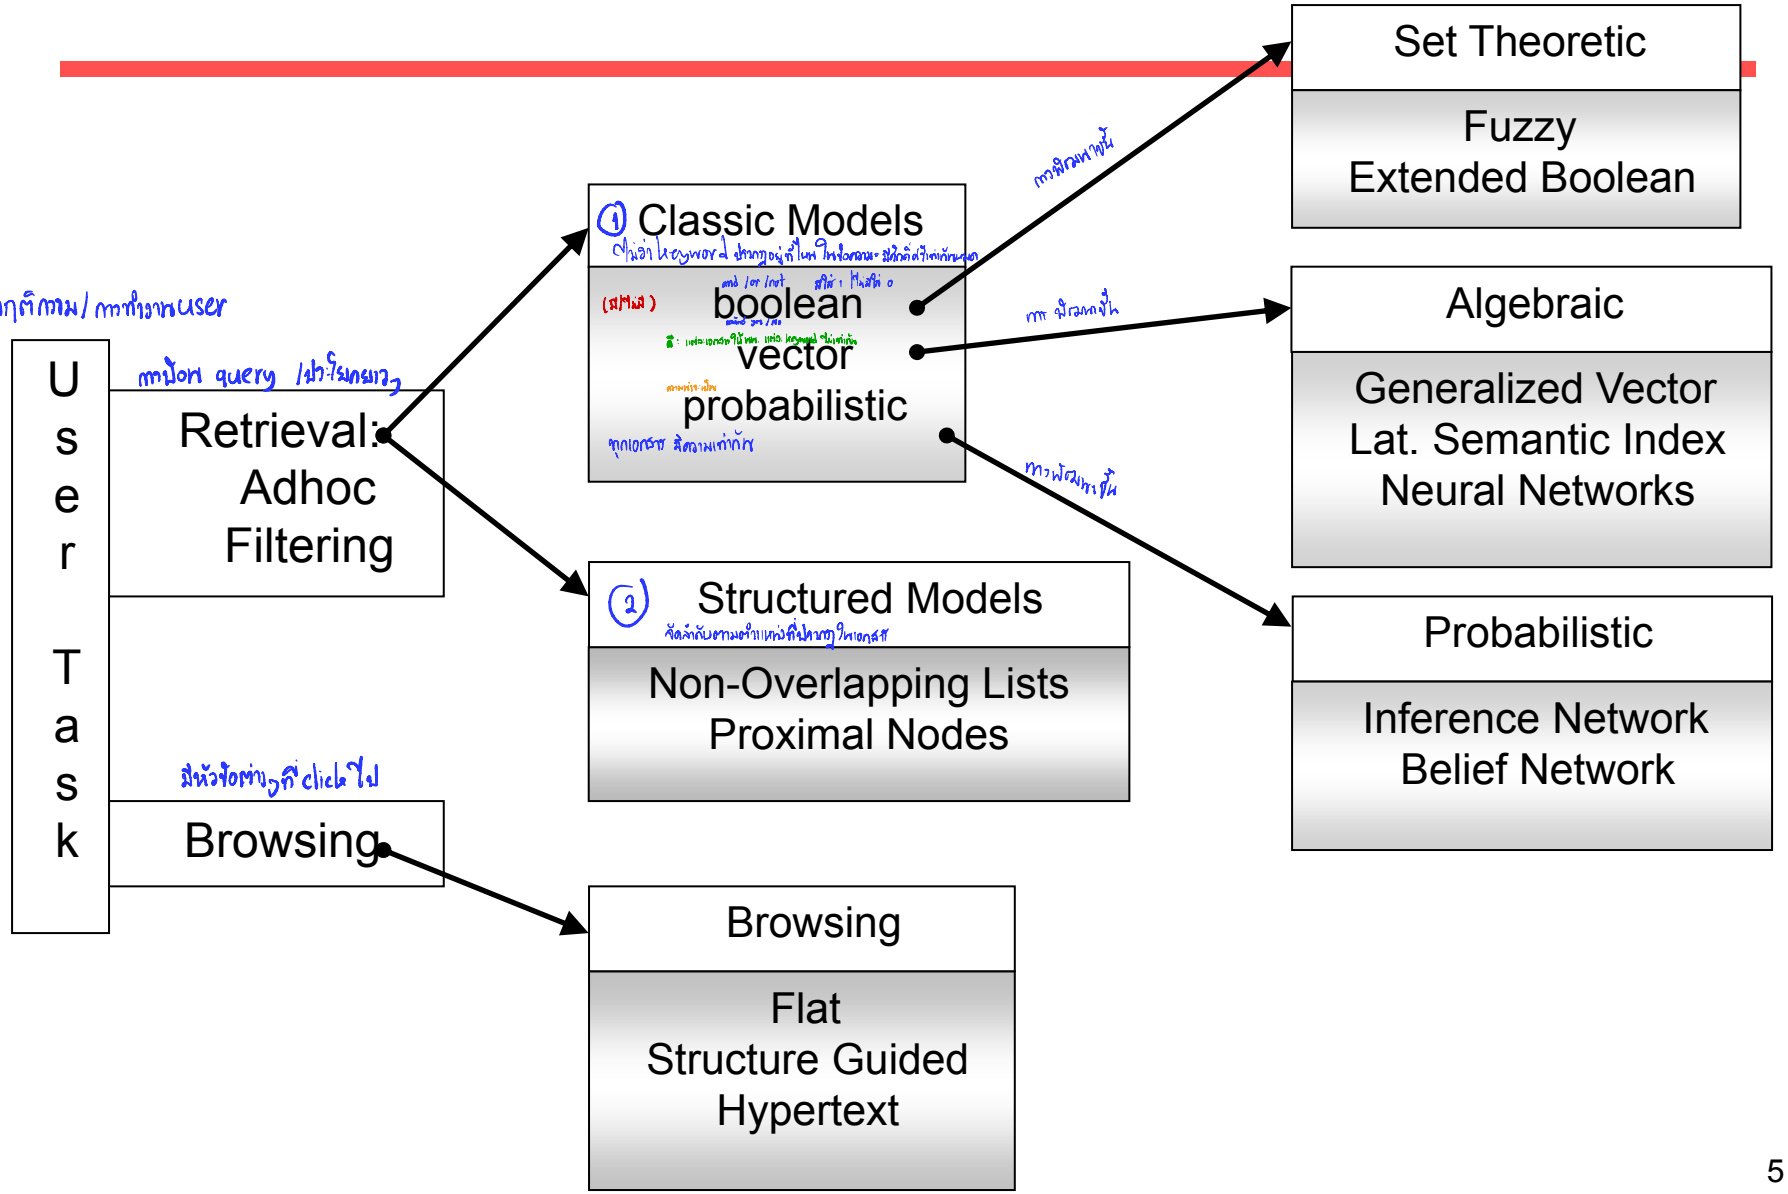
User Task
Retrieval: Adhoc Filtering
Browsing
1 Classic Models
boolean
vector
probabilistic
2 Structured Models
Non-Overlapping Lists
Proximal Nodes
Browsing
Flat
Structure Guided
Hypertext
Set Theoretic
Fuzzy
Extended Boolean
Algebraic
Generalized Vector
Lat. Semantic Index
Neural Networks
Probabilistic
Inference Network
Belief Network

IR Models

- The IR model, the logical view of the docs, and the retrieval task are distinct aspects of the system

LOGICAL VIEW OF DOCUMENTS

USER TASK	Index Terms	Full Text	Full Text + Structure
Retrieval	Classic Set Theoretic Algebraic Probabilistic	Classic Set Theoretic Algebraic Probabilistic	Structured
Browsing	Flat	Flat Hypertext	Structure Guided Hypertext

Retrieval : Ad hoc and Filtering

- **Ad hoc (Search)**: The documents in the collection remain relatively static while new queries are submitted to the system.
- **Routing (Filtering)**: The queries remain relatively static while new documents come into the system

Retrieval: Ad Hoc x Filtering

Ad hoc retrieval

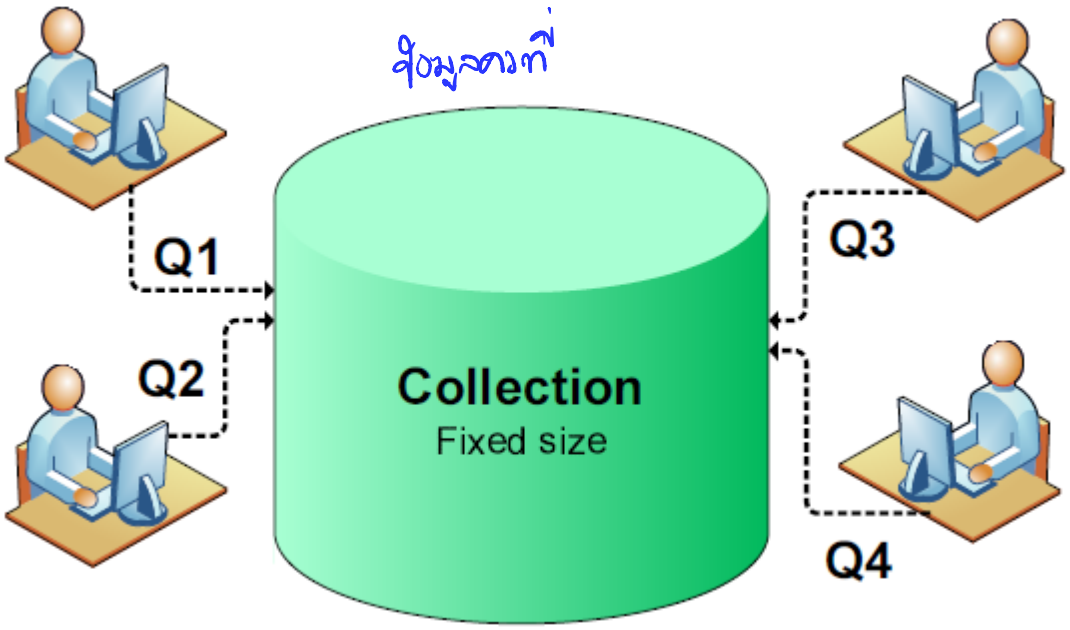

Retrieval: Ad Hoc x Filtering

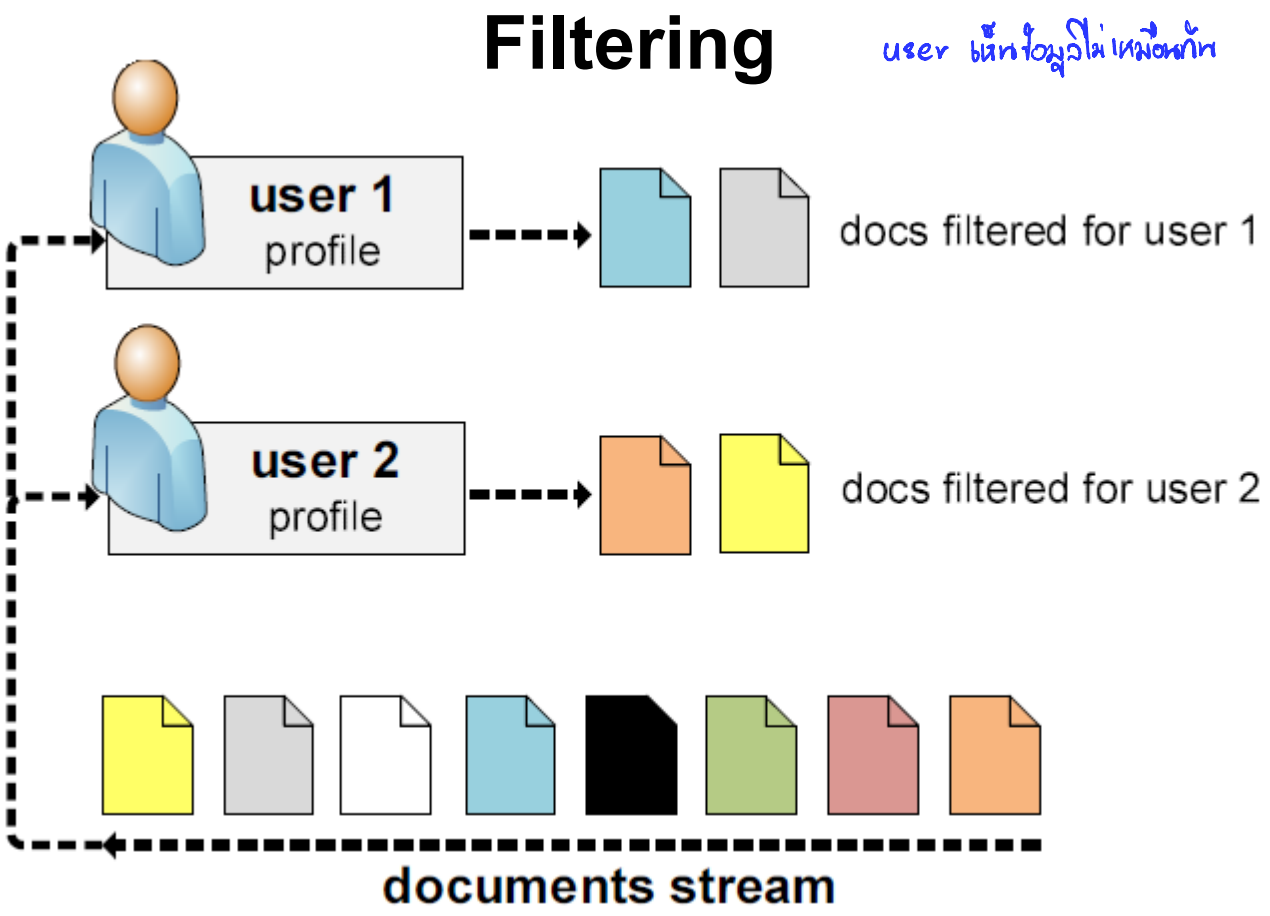

Classic IR Models - Basic Concepts

- Each document represented by **a set of representative keywords or index terms**
- An index term is a document word useful for remembering the document **main themes**
- Usually, index terms are **nouns** because nouns have meaning by themselves
- However, search engines assume that **all words are index terms** (full text representation)

Classic IR Models - Basic Concepts

- Not all terms are equally useful for representing the document contents: ***less frequent terms allow identifying a narrower set of documents***
- The *importance* of the index terms is represented by weights associated to them
- Let
  - k_i be an index term
  - d_j be a document
  - w_{ij} is a weight associated with (k_i, d_j)
- The weight w_{ij} quantifies the importance of the index term for describing the document contents

Classic IR Models - Basic Concepts

- K_i is an index term
- d_j is a document
- t is the total number of index terms จำนวน index
- $K = (k_1, k_2, \ldots, k_t)$ is the set of all index terms
- $w_{ij} >= 0$ is a weight associated with (k_i, d_j)
- $w_{ij} = 0$ ถ้าไม่เชื่อมโยงกัน indicates that term does not belong to doc
- $vec(d_j) = (w_{1j}, w_{2j}, \ldots, w_{tj})$ is a weighted vector associated with the document d_j
- $gi(vec(d_j)) = w_{ij}$ is a function which returns the weight associated with pair (k_i, d_j)

The Boolean Model

- Simple model based on set theory
- Queries specified as boolean expressions
  - precise semantics
  - neat formalism
  - $q = k_a \wedge (k_b \vee \neg k_c)$
- Terms are either **present or absent**. Thus, $w_{ij} \in \{0,1\}$
- Consider
  - $q = k_a \wedge (k_b \vee \neg k_c)$
  - $vec(qdnf) = (1,1,1) \vee (1,1,0) \vee (1,0,0)$
  - $vec(qcc) = (1,1,0)$ is a conjunctive component

The Boolean Model

$$q = k_a \wedge (k_b \vee \neg k_c)$$

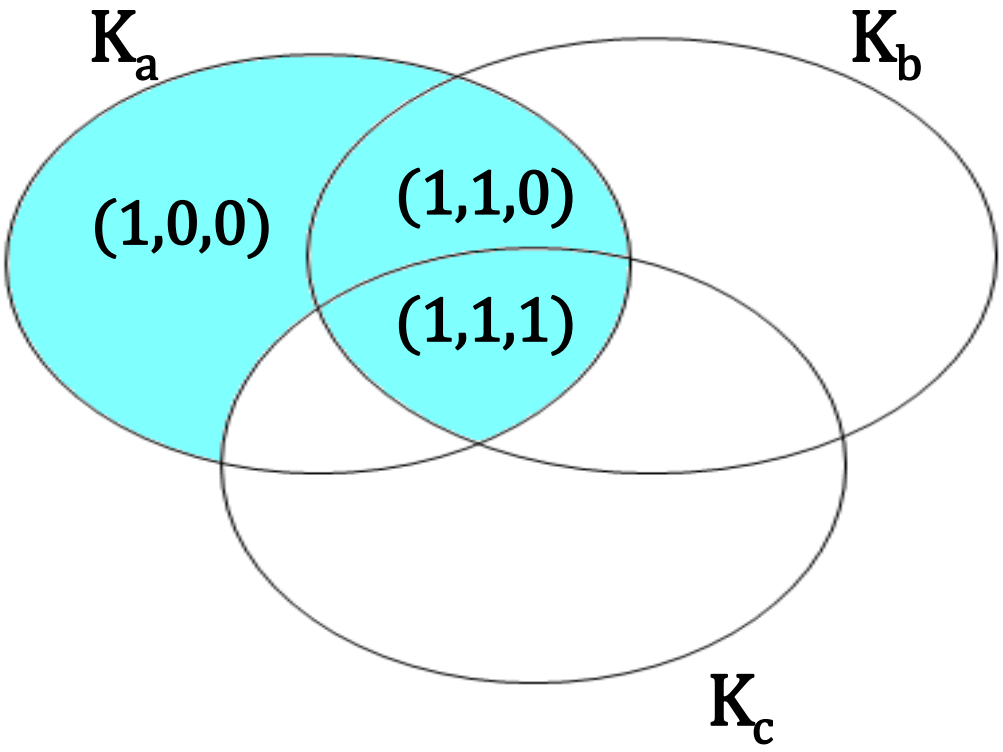

The Boolean Model Example

หน้าที่

เอกสารในระบบ

4 คำ จาก set ของ

$D_j = \{K_{dog}, K_{cat}, K_{tiger}\}$

$D_1 = \{1,1,0\}$

$D_2 = \{1,0,0\}$

$D_3 = \{1,0,1\}$

$D_4 = \{0,1,1\}$

$D_5 = \{0,0,1\}$

$D_6 = \{1,1,1\}$

$D_7 = \{1,0,0\}$

$D_8 = \{0,1,0\}$

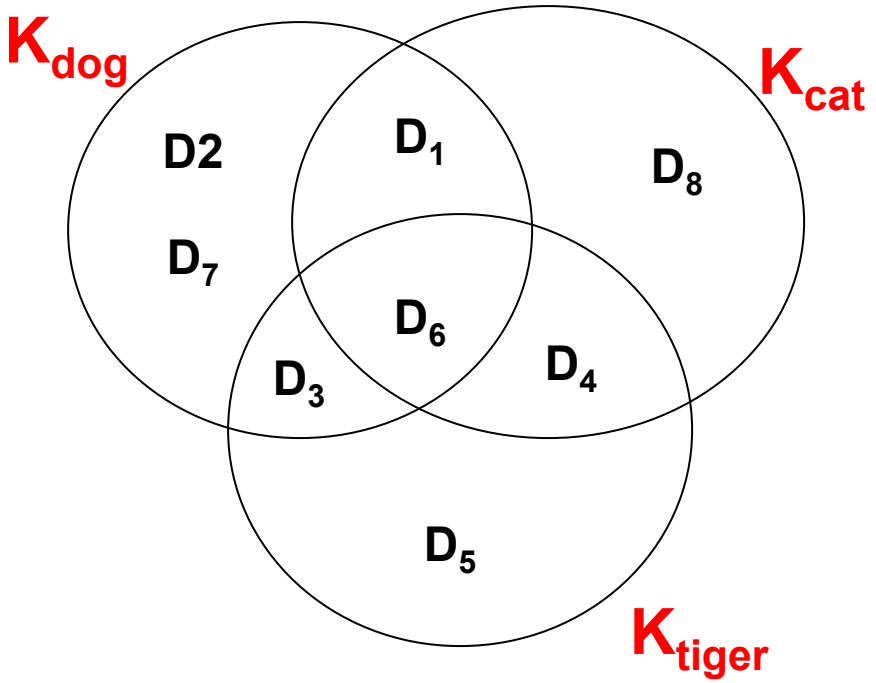

$$q = k_{dog} \wedge (k_{cat} \vee \neg k_{tiger})$$

Step 1

The Boolean Model Example

$$q = k_{dog} \wedge (k_{cat} \vee \neg k_{tiger})$$

$$(k_{cat} \vee \neg k_{tiger})$$

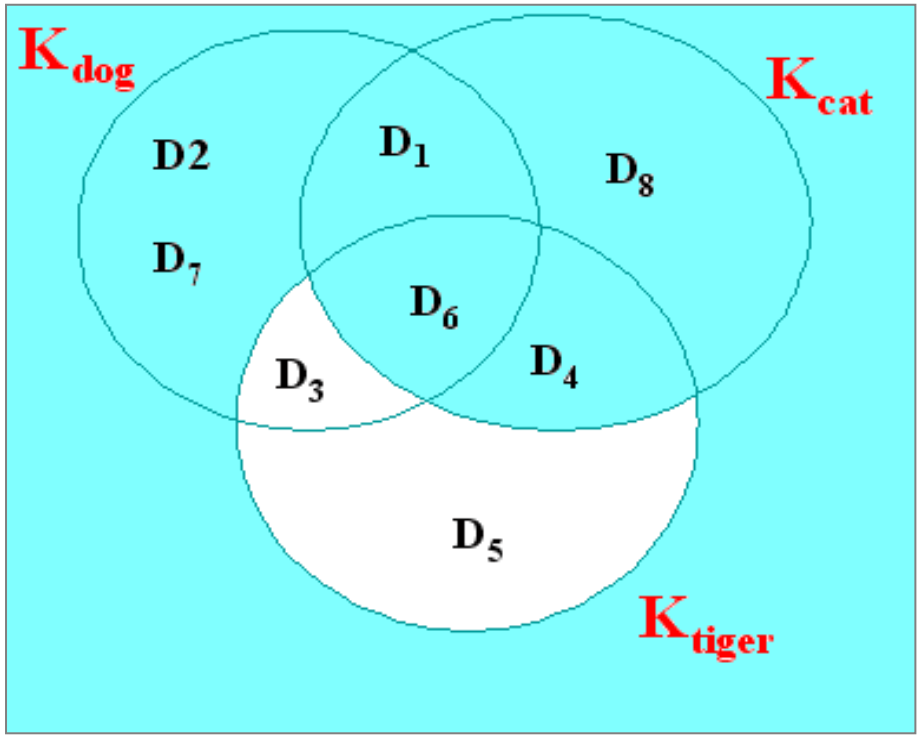

Step 2

The Boolean Model Example

$$q = k_{dog} \wedge (k_{cat} \vee \neg k_{tiger})$$

$k_{dog} \wedge (k_{cat} \vee \neg k_{tiger})$

Answer : **D1,D2,D6,D7**

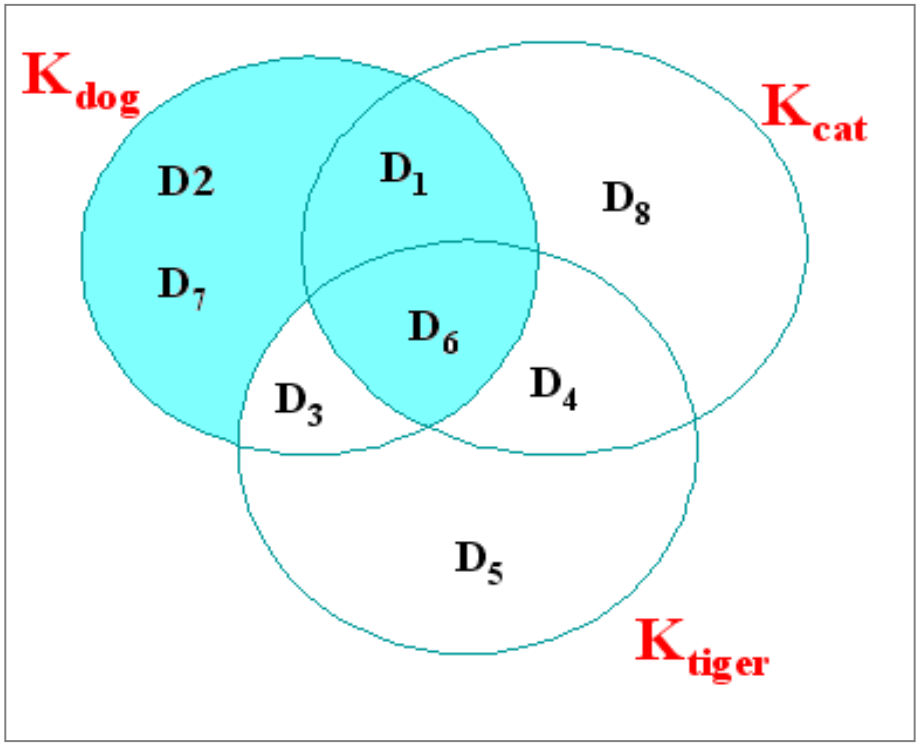

The Boolean Model Example

Terms: $K_1, \ldots, K_8$

$D_1 = \{K_1, K_2, K_3, K_4, K_5\}$
$D_2 = \{K_1, K_2, K_3, K_4\}$
$D_3 = \{K_2, K_4, K_6, K_8\}$
$D_4 = \{K_1, K_3, K_5, K_7\}$
$D_5 = \{K_4, K_5, K_6, K_7, K_8\}$
$D_6 = \{K_1, K_2, K_3, K_4\}$

Query: $K_1 \wedge (K_2 \vee \neg K_3)$

K_1 K_2 $\neg K_3$

Answer : $\{D_1, D_2, D_4, D_6\} \wedge (\{D_1, D_2, D_3, D_6\} \vee \{D_3, D_5\})$
$= \{D_1, D_2, D_6\}$

Boolean queries (cont.)

Example:

D1 = (A, B, C)

D2 = (A, C, D)

Query: (A **and** B) **or** (C **and** D)

and = เอาตัวร่วม

or = เอาตัวมาก

ตกลงในหน้าที่มี A and B หรือ C and D

	A and B	C and D	Relevance
D1	1	0 ไม่มี C,D	1
D2	ไม่มี A,B 0	1	1

Boolean queries (cont.)

Example:

D1 = (A, B, C)

D2 = (A, B, C, D)

Query: (A **and** ¬D)

	A and ¬D	**Relevance**
D1	1	1
D2	0	0

Boolean query extensions

Example:

D1 = (A, B, C)

D2 = (A, C, D)

Query: (A **and** B) **or** (C **and** D)

	A and B	C and D	Relevance
D1	min(1*1,1*1) = **1**	min(1*1,1*0)= **0**	max(1,0)= **1**
D2	min(1*1,1*0)= **0**	min(1*1,1*1) = **1**	max(0,1) = **1**

Boolean query extensions

D1 = (0.8A, 0.5B, 0.6C)
D2 = (0.4A, 0.4B, 0.1C, 0.8D)
Query: (0.5A **and** 0.2B) **Or** (**not** D Or 0.3C)

	A and B	Not D	Relevance
D1	min(0.5*0.8,0.2*0.5) =0.10	max(1,0.3*0.6) = 1	max(0.1,1) = **1**
D2	min(0.5*0.4,0.2*0.4) =0.08	max(0.2,0.3*0.1) = 0.2	max(0.08,0.2)= **0.2**

Drawbacks of the Boolean Model

ดีเรื่องของ common sent

- Retrieval based on **binary decision** criteria with no notion of partial matching
- **No ranking** of the documents is provided (absence of a grading scale)
- Information need has to be translated into a **Boolean expression** which most users find awkward

Boolean logic

- The Boolean queries formulated by the users are most often too simplistic
- As a consequence, the Boolean model frequently returns **either too few or too many documents** in response to a user query

The Vector Model

เลือกทุก keyword เป็นพจนาการ

- ความถี่ของการเกิด เช่น keyword แต่ละเอกสารมีได้
- แต่ละ query ไม่เท่ากัน } เอามา match คณิตกับ vector

- Use of binary weights is too limiting
- Non-binary weights provide consideration for **partial matches**
- These term weights are used to compute a ***degree of similarity*** between a query and each document

degree (ระดับของความคล้ายของ keyword)

- Ranked set of documents provides for better matching

The Vector Model: Example

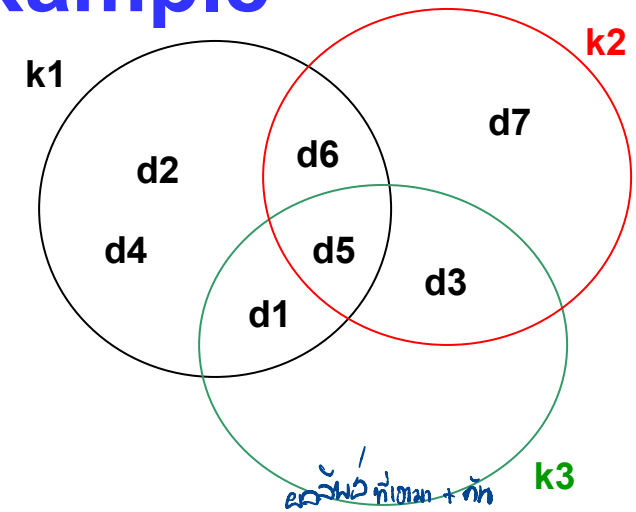

	k1	k2	k3	q • dj
d1	2	0	1	5
d2	1	0	0	1
d3	0	1	3	11
d4	2	0	0	2
d5	1	2	4	17
d6	1	2	0	5
d7	0	5	0	10
q	1	2	3	

Document Collection

- A collection of *n* documents can be represented in the vector space model by a term-document matrix.
- An entry in the matrix corresponds to the "weight" of a term in the document; zero means the term has no significance in the document or it simply doesn't exist in the document.

	T_1	T_2	….	T_t
D_1	w_{11}	w_{21}	…	w_{t1}
D_2	w_{12}	w_{22}	…	w_{t2}
:	:	:		:
:	:	:		:
D_n	w_{1n}	w_{2n}	…	w_{tn}

The Vector Model

- Define:
  - $w_{ij} > 0$ whenever $k_i \in d_j$
  - $w_{iq} >= 0$ associated with the pair (k_i, q)
  - $vec(d_j) = (w_{1j}, w_{2j}, \ldots, w_{tj})$
    $vec(q) = (w_{1q}, w_{2q}, \ldots, w_{tq})$
  - To each term k_i is associated a unitary vector *vec(i)*
  - The unitary vectors *vec(i)* and *vec(j)* are assumed to be orthonormal (i.e., index terms are assumed to occur independently within the documents)
- The *t* unitary vectors *vec(i)* form an orthonormal basis for a t-dimensional space
- In this space, queries and documents are represented as weighted vectors

The Vector Model

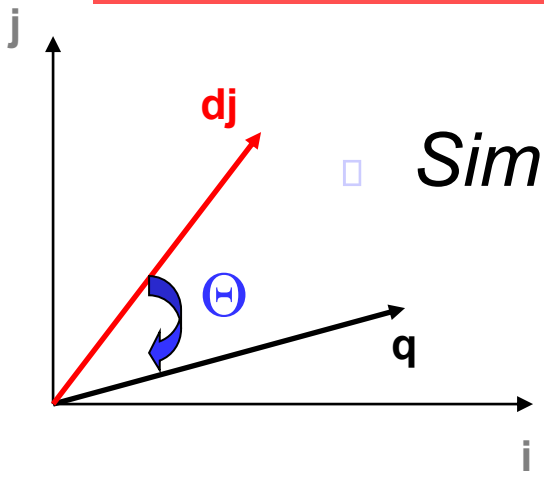

มุมน้อย = ความคล้ายมาก

- $Sim(q,d_j) = cos(\Theta)$

$$= \frac{\left(vec(d_j)*vec(q)\right)}{|d_j|*|q|} = \frac{\left(\sum w_{ij}*w_{iq}\right)}{|d_j|*|q|}$$

ขนาด เวกเตอร์ x ขนาด query

- Since $w_{ij} > 0$ and $w_{iq} > 0$,

  0 <= sim(q,d$_j$) <=1

- A document is retrieved even if it matches the query terms only partially

Graphic Representation

Example:

$D_1 = 2T_1 + 3T_2 + 5T_3$

$D_2 = 3T_1 + 7T_2 + T_3$

$Q = 0T_1 + 0T_2 + 2T_3$

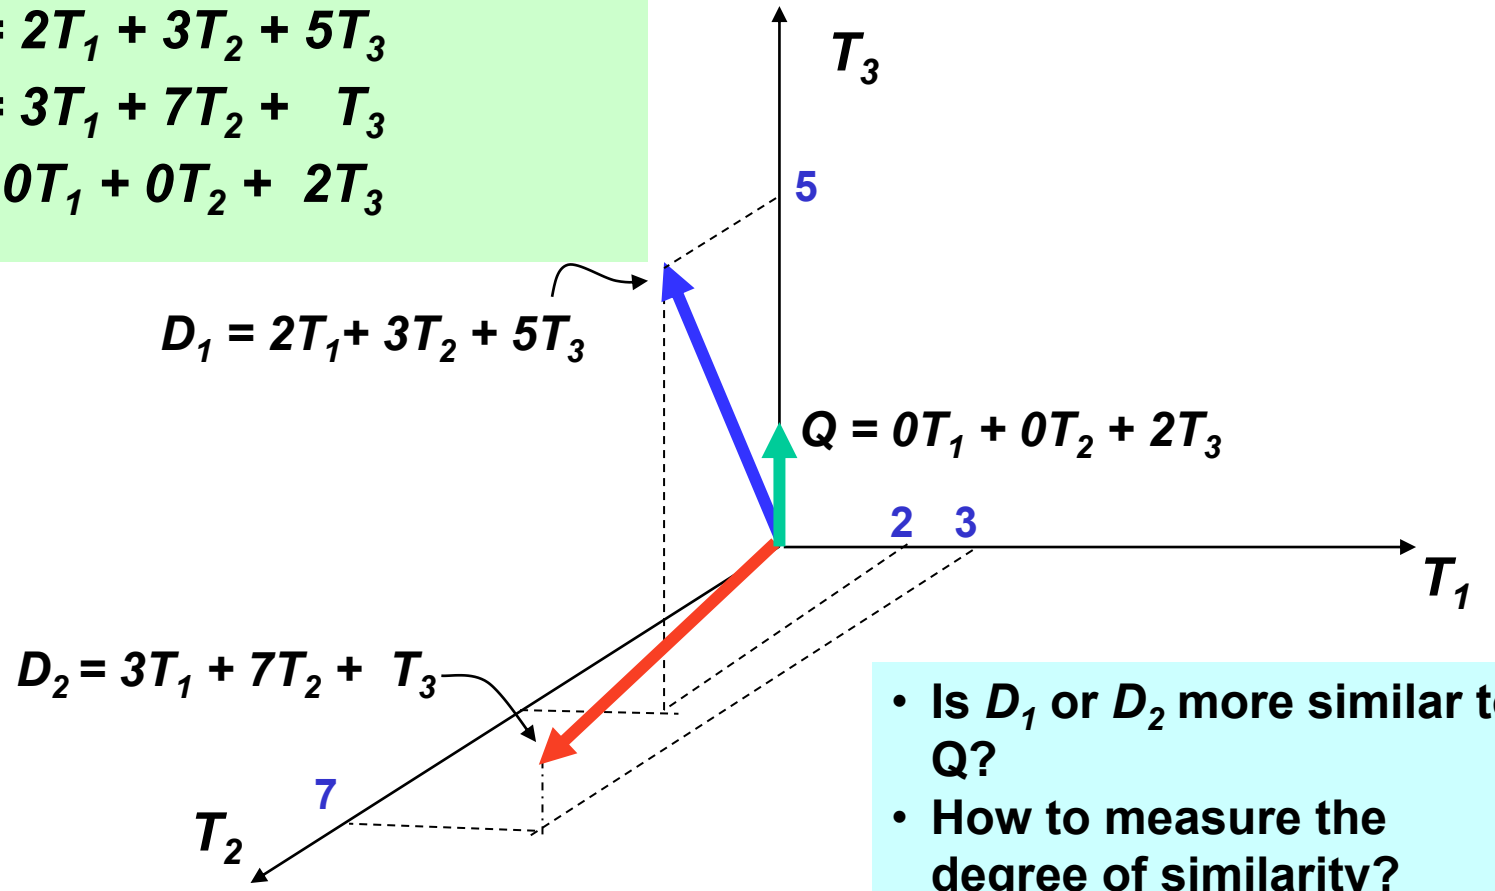

- Is D_1 or D_2 more similar to Q?
- How to measure the degree of similarity? Distance? Angle? Projection?

Cosine Similarity Measure

$$: \frac{(vec(d_j) * vec(q))}{|d_j| * |q|} = \frac{(\sum w_{ij} * w_{iq})}{|d_j| * |q|}$$

- **Cosine similarity measures the cosine of the angle between two vectors.**
- **Inner product normalized by the vector lengths.**

$$\text{CosSim}(d_j, q) = \frac{\vec{d_j} \cdot \vec{q}}{\left|\vec{d_j}\right| \cdot \left|\vec{q}\right|} = \frac{\sum_{i=1}^{t} (w_{ij} \cdot w_{iq})}{\sqrt{\sum_{i=1}^{t} w_{ij}^2 \cdot \sum_{i=1}^{t} w_{iq}^2}}$$

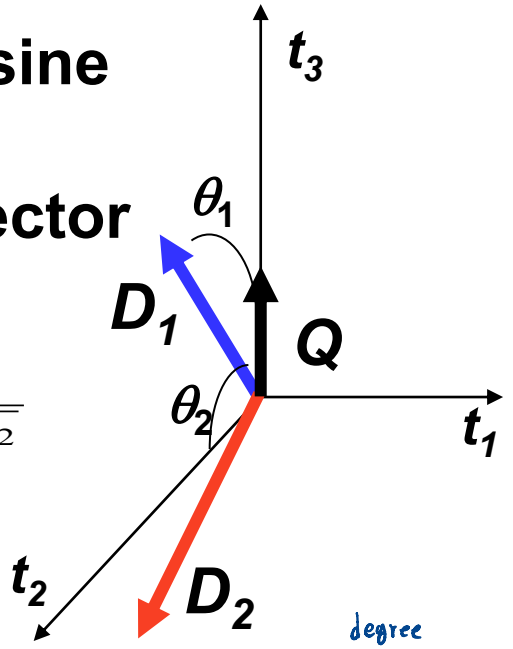

$D_1 = 2T_1 + 3T_2 + 5T_3$ $\quad \text{CosSim}(D_1, Q) = 10 / \sqrt{(4+9+25)(0+0+4)} = 0.81$

$D_2 = 3T_1 + 7T_2 + 1T_3$ $\quad \text{CosSim}(D_2, Q) = 2 / \sqrt{(9+49+1)(0+0+4)} = 0.13$

$Q = 0T_1 + 0T_2 + 2T_3$

Computing Similarity Scores

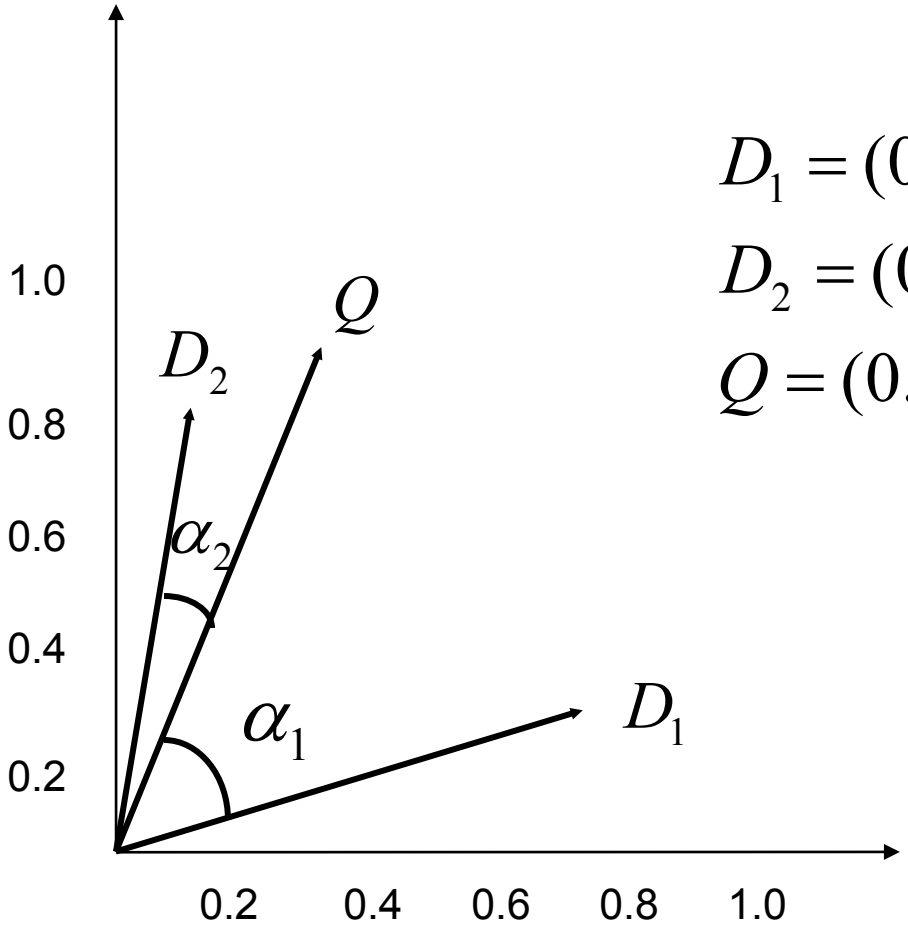

$$D_1 = (0.8, 0.3)$$

$$D_2 = (0.2, 0.7)$$

$$Q = (0.4, 0.8)$$

Computing a similarity score

Say we have query vector $Q = (0.4, 0.8)$

Also, document $D_2 = (0.2, 0.7)$

What does their similarity comparison yield?

$$sim(Q, D_2) = \frac{(0.4 * 0.2) + (0.8 * 0.7)}{\sqrt{[(0.4)^2 + (0.8)^2] * [(0.2)^2 + (0.7)^2]}}$$

$$= \frac{0.64}{\sqrt{0.42}} = 0.98$$

Vector Space with Term Weights and Cosine Matching

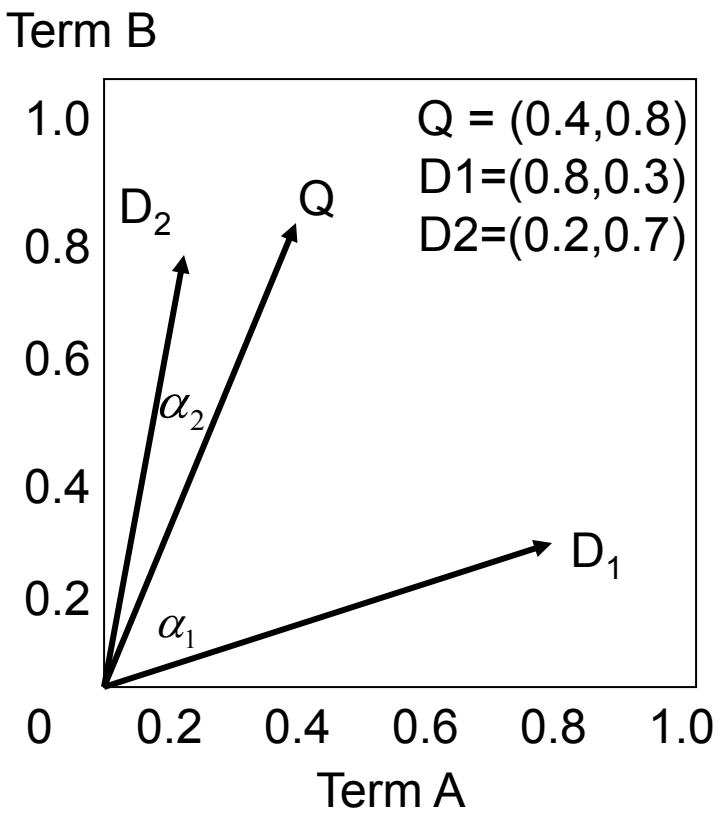

$D_i=(d_{i1},w_{di1};d_{i2}, w_{di2};\ldots;d_{it}, w_{dit})$

$Q=(q_{i1},w_{qi1};q_{i2}, w_{qi2};\ldots;q_{it}, w_{qit})$

$$sim(Q,D_i)=\frac{\sum_{j=1}^{t} w_{q_j} w_{d_{ij}}}{\sqrt{\sum_{j=1}^{t}(w_{q_j})^2 \sum_{j=1}^{t}(w_{d_{ij}})^2}}$$

$$sim(Q,D2)=\frac{(0.4\cdot 0.2)+(0.8\cdot 0.7)}{\sqrt{[(0.4)^2+(0.8)^2]\cdot[(0.2)^2+(0.7)^2]}}$$

$$=\frac{0.64}{\sqrt{0.42}}=0.98$$

$$sim(Q,D_1)=\frac{0.56}{\sqrt{0.58}}=0.74$$

The Vector Model

ตามชื่อของ Vector

- $Sim(q,dj) = \frac{\left(\sum w_{ij} * w_{iq}\right)}{|d_j| * |q|}$

หาจาก เช่น keyword ที่ใช้

- How to compute the weights w_{ij} and w_{iq} ?
- A good weight must take into account two effects:
  - quantification of ***intra-document*** contents (similarity) หมายถึง 1 เอกสาร ดูว่า keyword นั้นปรากฏในเอกสาร (เดียว) กี่ครั้ง
    - *tf* factor, the ***term frequency*** within **a document**
  - quantification of ***inter-documents*** separation (dissimilarity) ดูจากหลายๆ เอกสาร ว่าความถี่ keyword เท่าไร
    - *idf* factor, the ***inverse document frequency***
  - $w_{ij} = tf(i,j) * idf(i)$

TF-IDF Weighting

- A typical combined term importance indicator is *tf-idf weighting*:

$$W_{ij} = tf_{ij} * idf_i = tf_{ij} * \log(\frac{N}{n_i})$$

- A term occurring frequently in the document but rarely in the rest of the collection is given ***high weight***.
- Many other ways of determining term weights have been proposed.
- Experimentally, *tf-idf* has been found to work well.

Computing TF-IDF -- An Example

เอกสาร 5

Given **a document** containing terms with given frequencies:
(intra-document)

A(3), B(2), C(1)

Assume **collection contains** 10,000 documents and document frequencies of these terms are:
(inter-documents) ความถี่ที่ทั้งหมด

A(50), B(1300), C(250)

Then:

A: tf = 3/3; idf = log(10000/50) = 2.30; tf*idf = 2.30
B: tf = 2/3; idf = log(10000/1300) = 0.89; tf*idf = 0.59
C: tf = 1/3; idf = log(10000/250) = 1.61; tf*idf = 0.53

tf = เอาตัวบน / max
idf = จำนวนเอกสารทั้งหมด / เอกสารที่มี keyที่ใช้

การคิดทุกเอกสาร 5 ต้องทำทุกเอกสาร

Example

ตอนนี้ มี keyword ปรากฏที่นี้

1) Once upon a **midnight** dreary, while I pondered, weak and weary.
2) Over many a quaint and curious **volume** of forgotten **lore**.
3) While I nodded, nearly napping, suddenly there came a **tap**ping.
4) As of some one gently rapping **door**, rapping at my **chamber door**.
5) "Tis some **visitor**," I muttered, "tapping at my **chamber door**" .
6) Only this, and **nothing** more.

N=6

Key1 "**chamber**" *frequency* = 2

Key2 "**door**" *frequency* = 3

Key3 "**lore**" *frequency* = 1

Key4 "**midnight**" *frequency* = 1

Key5 "**nothing**" *frequency* = 1

Key6 "**tap**" *frequency* = 1

Key7 "**visitor**" *frequency* = 1

Key8 "**volumn**" *frequency* = 1

Example ตัวอย่าง

	chamber	door	lore	midnight	nothing	tap	visitor	volume
Doc1	0	0	0	1	0	0	0	0
Doc2	0	0	1	0	0	0	0	1
Doc3	0	0	0	0	0	1	0	0
Doc4	1	2	0	0	0	0	0	0
Doc5	1	1	0	0	0	0	1	0
Doc6	0	0	0	0	1	0	0	0

Computing TF-IDF (Only Doc4)

-Given a document containing terms with given frequencies:

Chamber(1), Door(2) --- > max = 2

- collection contains 6 documents

Chamber(2), Door(2)

Then:

Chamber:

tf = 1/2; idf = log(6/2) = 0.48; tf*idf = 0.24

Door:

tf = 2/2; idf = log(6/2) = 0.48; tf*idf = 0.48

Example

	chamber	door	lore	midnight	nothing	tap	visitor	volume
Doc1	0	0	0	0.78	0	0	0	0
Doc2	0	0	0.78	0	0	0	0	0.78
Doc3	0	0	0	0	0	0.78	0	0
Doc4	0.24	0.48	0	0	0	0	0	0
Doc5	0.48	0.48	0	0	0	0	0.78	0
Doc6	0	0	0	0	0.78	0	0	0

The Vector Model

- Let,
  - N be the total number of docs in the collection
  - n_i be the number of docs which contain ki
  - $freq(i,j)$ raw frequency of k_i within d_j
- A normalized tf factor is given by
  - $\mathbf{f(i,j) = freq(i,j) / max(freq(l,j))}$
  - where ***the maximum is computed over all terms which occur within the document*** $\mathbf{d_j}$
- The idf factor is computed as
  - $\mathbf{idf(i) = log(N/n_i)}$
  - the *log* is used to make the values of tf and idf comparable. It can also be interpreted as the *amount of information* associated with the term k_i.

The Vector Model

- The best term-weighting schemes use weights which are give by
  - *wij = f(i,j) * log(N/ni)*
  - the strategy is called a *tf-idf* weighting scheme
- For the query term weights, a suggestion is

$$W_{i,q} = \left(0.5 + \frac{0.5 * freq_{i,q}}{Max(freq_{I,q})}\right) * \log\left(\frac{N}{n_i}\right)$$

- The vector model with *tf-idf* weights is a good ranking strategy with general collections
- The vector model is usually as good as the known ranking alternatives. It is also simple and fast to compute.

The Vector Model

Query: "**Visitor** at your **door** or my **door**"

Translation to known keyterms: { "**visitor**","**door**","**door**" }

$$W_{i,q} = (0.5 + \frac{0.5 * freq_{i,q}}{Max(freq_{i,q})}) * \log(\frac{N}{n_i})$$

Door $W_{2,q} = (0.5 + \frac{0.5*2}{2}) * \log(\frac{6}{2}) = 0.477$

Visitor $W_{7,q} = (0.5 + \frac{0.5*1}{2}) * \log(\frac{6}{1}) = 0.584$

Resulting query vector = (0,0.477,0,0,0,0,0.584,0)

Example

	chamber	door	lore	midnight	nothing	tap	visitor	volume
Doc1	0	0	0	0.78	0	0	0	0
Doc2	0	0	0.78	0	0	0	0	0.78
Doc3	0	0	0	0	0	0.78	0	0
Doc4	0.24	0.48	0	0	0	0	0	0
Doc5	0.48	0.48	0	0	0	0	0.78	0
Doc6	0	0	0	0	0.78	0	0	0
q	**0**	**0.477**	**0**	**0**	**0**	**0**	**0.584**	**0**

$$sim(Q, D_i) = \frac{\sum_{j=1}^{t} w_{q_j} w_{d_{ij}}}{\sqrt{\sum_{j=1}^{t} (w_{q_j})^2 \sum_{j=1}^{t} (w_{d_{ij}})^2}}$$

$$sim(Q, D_4) = \frac{0.48 * 0.477}{\sqrt{[(0.477)^2 + (0.584)^2] * [(0.24)^2 + (0.48)^2]}}$$

$$= \frac{0.229}{0.405} = 0.566$$

$$sim(Q, D_1) = sim(Q, D_2)$$
$$= sim(Q, D_3)$$
$$= sim(Q, D_6)$$
$$= 0$$

$$sim(Q, D_5) = \frac{(0.48 * 0.477) + (0.78 * 0.584)}{\sqrt{[(0.477)^2 + (0.584)^2] * [(0.48)^2 + (0.48)^2 + (0.78)^2]}}$$

$$= \frac{0.684}{0.779} = 0.879$$

ลำดับความคล้ายเดิม

New Rank → **$D_5, D_4, D_1, D_2, D_3, D_6$**

TF-IDF Smoothing

$$tf_{i,j} = \frac{f_{i,j}}{max_i f_{i,j}}$$

	Cat	Dog	Tiger
D1	2	5	1
D2	1	4	0
D3	5	2	7
D4	2	1	0

$$tf_{dog,1} = \frac{5}{5} = 1$$

$$tf_{dog,2} = \frac{4}{4} = 1$$

TF-IDF Smoothing

$$tf_{i,j} = \frac{f_{i,j}}{max_i f_{i,j}}$$

อาจจะมีอย่างอื่นอีกว่า ถ้าใช้สูตรที่แตกต่างออกไป

	tf weight
binary	{0,1}
raw frequency	$f_{i,j}$
log normalization	$1 + \log f_{i,j}$
double normalization 0.5	$0.5 + 0.5\frac{f_{i,j}}{max_i f_{i,j}}$
double normalization K	$K + (1-K)\frac{f_{i,j}}{max_i f_{i,j}}$

ตย. ใช้อันนี้

TF-IDF Smoothing

$$idf_i = \log(\frac{N}{n_i})$$

	Cat	Dog	Tiger
D1	2	5	1
D2	1	4	0
D3	5	2	7
D4	2	1	0

$$idf_{cat} = \log(\frac{4}{4}) = 0 \qquad w_{cat,j} = x * 0 = 0$$

$$idf_{dog} = \log(\frac{4}{4}) = 0 \qquad w_{dog,j} = x * 0 = 0$$

TF-IDF Smoothing

$$idf_i = \log(\frac{N}{n_i})$$

สาม

	idf weight
unary	1
inverse frequency	$\log \frac{N}{n_i}$ *สอบ ส่วนมากใช้ตัวนี้ → ตย.ใช้อันนี้
inv frequency smooth	$\log(1 + \frac{N}{n_i})$
inv frequeny max	$\log(1 + \frac{max_i n_i}{n_i})$
probabilistic inv frequency	$\log \frac{N - n_i}{n_i}$ ส่วนมากใช้อันนี้

<u>ตัวอย่าง</u> สมมติในระบบมีเอกสาร 10 เอกสารดังนี้ (bird, cat, dog, tiger คือ **Keyword ซึ่งไม่มีความสัมพันธ์กัน**)

D1: {bird,cat,bird,cat,dog,dog,bird}
D2: {cat,tiger,cat,dog}
D3: {dog,bird,bird}
D4: {cat,tiger}
D5: {tiger,tiger,dog,tiger,cat}
D6: {bird,cat,bird,cat,tiger,tiger,bird}
D7: {bird,tiger,cat,dog}
D8: {dog,cat,bird}
D9: {cat,dog,tiger}
D10: {tiger,tiger,tiger}

เด็กหญิงดาวิกาส่งคำเรียกค้น ”แมว สุนัข เสือ แมว” เข้าไปในระบบ จงตอบคำถาม

2.1 เพื่อคำนวณหา Ranking ของเอกสารทุกเอกสารในระบบ เด็กหญิงดาวิกา**สามารถเลือกใช้โมเดลใดได้บ้าง เพราะอะไร**

A) BM25 Model **B)** Fuzzy Model **C)** Extend Boolean Model
D) Vector Model **E)** Probabilistic Model **F)** Generalized Vector Model

2.2 จากข้อ 2.1 ให้นักศึกษาแสดงวิธีคำนวณหา Ranking ของเอกสารทุกเอกสารในระบบ ตามโมเดลที่เด็กหญิงดาวิกาเลือก

ตัวอย่าง สมมติในระบบมีเอกสาร 10 เอกสารดังนี้ (bird, cat, dog, tiger คือ **Keyword ซึ่งไม่มีความสัมพันธ์กัน**)

D1: {bird,cat,bird,cat,dog,dog,bird}
D2: {cat,tiger,cat,dog}
D3: {dog,bird,bird}
D4: {cat,tiger}
D5: {tiger,tiger,dog,tiger,cat}
D6: {bird,cat,bird,cat,tiger,tiger,bird}
D7: {bird,tiger,cat,dog}
D8: {dog,cat,bird}
D9: {cat,dog,tiger}
D10: {tiger,tiger,tiger}

เด็กหญิงดาวิกาส่งคำเรียกค้น ”แมว สุนัข เสือ แมว” เข้าไปในระบบ จงตอบคำถาม

2.1 เพื่อคำนวณหา Ranking ของเอกสารทุกเอกสารในระบบ เด็กหญิงดาวิกา**สามารถเลือกใช้โมเดลใดได้บ้าง เพราะอะไร**

A) BM25 Model **B)** Fuzzy Model **C)** Extend Boolean Model
D) Vector Model **E)** Probabilistic Model **F)** Generalized Vector Model

2.2 จากข้อ 2.1 ให้นักศึกษาแสดงวิธีคำนวณหา Ranking ของเอกสารทุกเอกสารในระบบ ตามโมเดลที่เด็กหญิงดาวิกาเลือก

Answer

2.1 เลือกใช้ BM25 Model และ Vector Model เนื่องจากลักษณะของ Query เป็น keyword แยกกัน ไม่มี Expression และโจทย์กำหนดให้ Keyword ไม่สัมพันธ์กัน

Vector 1

เอกสาร 10 เอกสารมีการแจกแจง Keyword ดังนี้

D1: {bird,cat,bird,cat,dog,dog,bird}
D2: {cat,tiger,cat,dog}
D3: {dog,bird,bird}
D4: {cat,tiger}
D5: {tiger,tiger,dog,tiger,cat}
D6: {bird,cat,bird,cat,tiger,tiger,bird}
D7: {bird,tiger,cat,dog}
D8: {dog,cat,bird}
D9: {cat,dog,tiger}
D10: {tiger,tiger,tiger}

	Bird	Cat	Dog	Tiger	Max
Doc1	3	2	2	0	3
Doc2	0	2	1	1	2
Doc3	2	0	1	0	2
Doc4	0	1	0	1	1
Doc5	0	1	1	3	3
Doc6	3	2	0	2	3
Doc7	1	1	1	1	1
Doc8	1	1	1	0	1
Doc9	0	1	1	1	1
Doc10	0	0	0	3	3
n	5	8	7	7	

Vector 1

Only Doc1

	Bird	Cat	Dog	Tiger	Max
Doc1	3	2	2	0	3
Doc2	0	2	1	1	2
Doc3	2	0	1	0	2
Doc4	0	1	0	1	1
Doc5	0	1	1	3	3
Doc6	3	2	0	2	3
Doc7	1	1	1	1	1
Doc8	1	1	1	0	1
Doc9	0	1	1	1	1
Doc10	0	0	0	3	3
n	5	8	7	7	

$$tf_{bird} = \frac{3}{3} = 1.000$$
$$tf_{cat} = \frac{2}{3} = 0.667$$
$$tf_{dog} = \frac{2}{3} = 0.667$$
$$tf_{tiger} = \frac{0}{3} = 0.000$$

$$idf_{bird} = \log(\frac{10}{5}) = 0.301$$
$$idf_{cat} = \log(\frac{10}{8}) = 0.097$$
$$idf_{dog} = \log(\frac{10}{7}) = 0.155$$
$$idf_{tiger} = \log(\frac{10}{7}) = 0.155$$

$$\boldsymbol{w_{bird} = 1.000 * 0.301 = 0.301}$$
$$\boldsymbol{w_{cat} = 0.667 * 0.097 = 0.065}$$
$$\boldsymbol{w_{dog} = 0.667 * 0.155 = 0.103}$$
$$\boldsymbol{w_{tiger} = 0.000 * 0.155 = 0.000}$$

Vector 1

น้ำหนักของแต่ละ Keyword ในแต่ละเอกสาร

	Bird	Cat	Dog	Tiger
Doc1	0.301	0.065	0.103	0.000
Doc2	0.000	0.097	0.077	0.077
Doc3	0.301	0.000	0.077	0.000
Doc4	0.000	0.097	0.000	0.155
Doc5	0.000	0.032	0.052	0.155
Doc6	0.301	0.065	0.000	0.103
Doc7	0.301	0.097	0.155	0.155
Doc8	0.301	0.097	0.155	0.000
Doc9	0.000	0.097	0.155	0.155
Doc10	0.000	0.000	0.000	0.155

Vector 2

Query = แมว สุนัข เสือ แมว

$$W_{i,q} = \left(0.5 + \frac{0.5 * freq_{i,q}}{Max(freq_{I,q})}\right) * \log(\frac{N}{n_i})$$

$$W_{bird,q} = \left(0.5 + \frac{0.5 * 0}{2}\right) * 0.301 = 0.151$$

$$W_{cat,q} = \left(0.5 + \frac{0.5 * 2}{2}\right) * 0.097 = 0.097$$

$$W_{dog,q} = \left(0.5 + \frac{0.5 * 1}{2}\right) * 0.155 = 0.117$$

$$W_{dog,q} = \left(0.5 + \frac{0.5 * 1}{2}\right) * 0.155 = 0.117$$

	Bird	Cat	Dog	Tiger
Doc1	0.301	0.065	0.103	0.000
Doc2	0.000	0.097	0.077	0.077
Doc3	0.301	0.000	0.077	0.000
Doc4	0.000	0.097	0.000	0.155
Doc5	0.000	0.032	0.052	0.155
Doc6	0.301	0.065	0.000	0.103
Doc7	0.301	0.097	0.155	0.155
Doc8	0.301	0.097	0.155	0.000
Doc9	0.000	0.097	0.155	0.155
Doc10	0.000	0.000	0.000	0.155

$$idf_{bird} = \log(\frac{10}{5}) = 0.301$$

$$idf_{cat} = \log(\frac{10}{8}) = 0.097$$

$$idf_{dog} = \log(\frac{10}{7}) = 0.155$$

$$idf_{tiger} = \log(\frac{10}{7}) = 0.155$$

Vector 3

Query = แมว สุนัข เสือ แมว

$$sim(d_j, q) = \frac{\sum_{j=1}^{t} w_{q_j} w_{d_{ij}}}{\sqrt{\sum_{j=1}^{t} (w_{q_j})^2 \sum_{j=1}^{t} (w_{d_{ij}})^2}}$$

	Bird	Cat	Dog	Tiger
Doc1	0.301	0.065	0.103	0.000
Doc2	0.000	0.097	0.077	0.077
Doc3	0.301	0.000	0.077	0.000
Doc4	0.000	0.097	0.000	0.155
Doc5	0.000	0.032	0.052	0.155
Doc6	0.301	0.065	0.000	0.103
Doc7	0.301	0.097	0.155	0.155
Doc8	0.301	0.097	0.155	0.000
Doc9	0.000	0.097	0.155	0.155
Doc10	0.000	0.000	0.000	0.155
q	0.151	0.097	0.117	0.117

$$sim(d_1, q) = \frac{0.301 * 0.151 + 0.065 * 0.097 + 0.103 * 0.117 + 0.0 * 0.117}{\sqrt{(0.1512 + 0.0972 + 0.1172 + 0.1172)(0.3012 + 0.0652 + 0.1032 + 0)}}$$

$$= 0.806$$

Vector 4

Query = แมว สุนัข เสือ แมว

	Sim
Doc1	0.806
Doc2	0.771
Doc3	0.719
Doc4	0.617
Doc5	0.671
Doc6	0.806
Doc7	0.970
Doc8	0.850
Doc9	0.780
Doc10	0.478

Rank →

	Sim
Doc7	0.970
Doc8	0.850
Doc1	0.806
Doc6	0.806
Doc9	0.780
Doc2	0.771
Doc3	0.719
Doc5	0.671
Doc4	0.617
Doc10	0.478

	Bird	Cat	Dog	Tiger
Doc1	0.301	0.065	0.103	0.000
Doc2	0.000	0.097	0.077	0.077
Doc3	0.301	0.000	0.077	0.000
Doc4	0.000	0.097	0.000	0.155
Doc5	0.000	0.032	0.052	0.155
Doc6	0.301	0.065	0.000	0.103
Doc7	0.301	0.097	0.155	0.155
Doc8	0.301	0.097	0.155	0.000
Doc9	0.000	0.097	0.155	0.155
Doc10	0.000	0.000	0.000	0.155
q	0.151	0.097	0.117	0.117

Rank → D7,D8,D6,D1,D9,D2,D3,D5,D4,D10

Modeling
(Structured Text Models)

Introduction

- Keyword-based query answering considers that *the documents are **flat*** i.e., a word in the title has the same weight as a word in the body of the document
- But, the document structure is one additional piece of information which can be taken advantage of
- For instance, words appearing in the title or in sub-titles within the document could receive higher

Basic Definitions

- ***Match point:*** the position in the text of a sequence of words that match the query
  - Query: "atomic holocaust in Hiroshima"
  - Doc d_j: contains 3 lines with this string
  - Then, doc d_j contains 3 match points
- ***Region*****:** a contiguous portion of the text
- ***Node*****:** a structural component of the text such as a chapter, a section, etc

Non-Overlapping Lists

- Due to Burkowski, 1992.
- Idea: divide the text in *non-overlapping* regions which are collected in a *list*
- Multiple ways to divide the text in non-overlapping parts yield multiple lists:
  - a list for chapters
  - a list for sections
  - a list for subsections
- Text regions from distinct lists might overlap

Non-Overlapping Lists

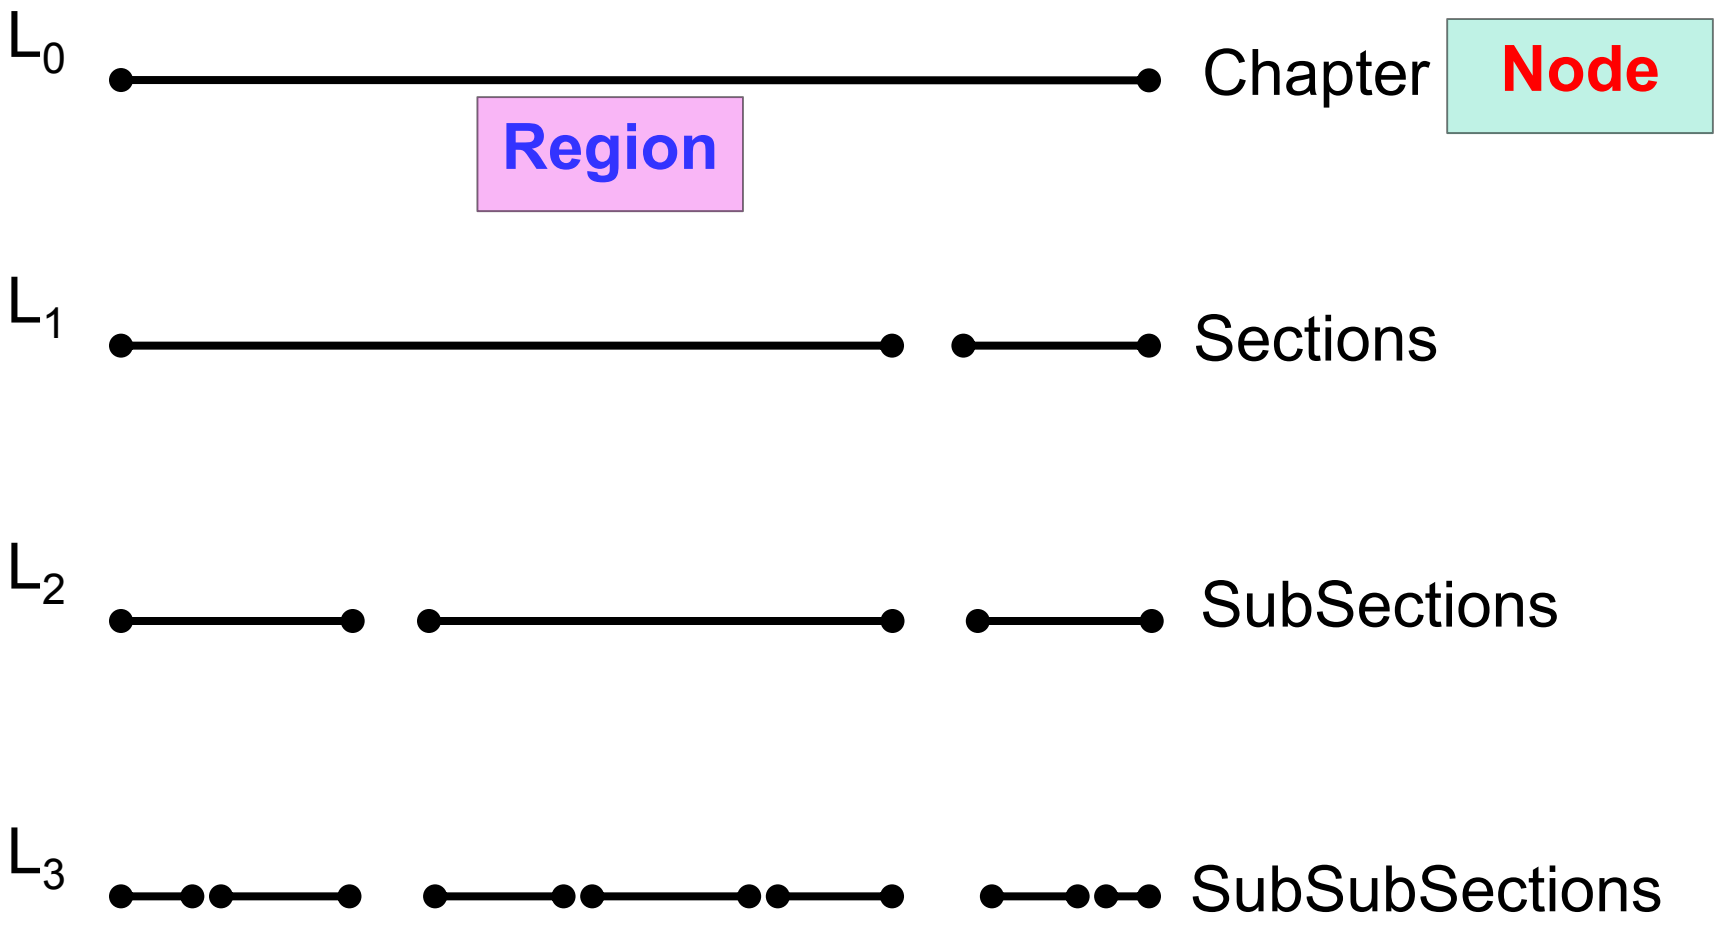

Non-Overlapping Lists

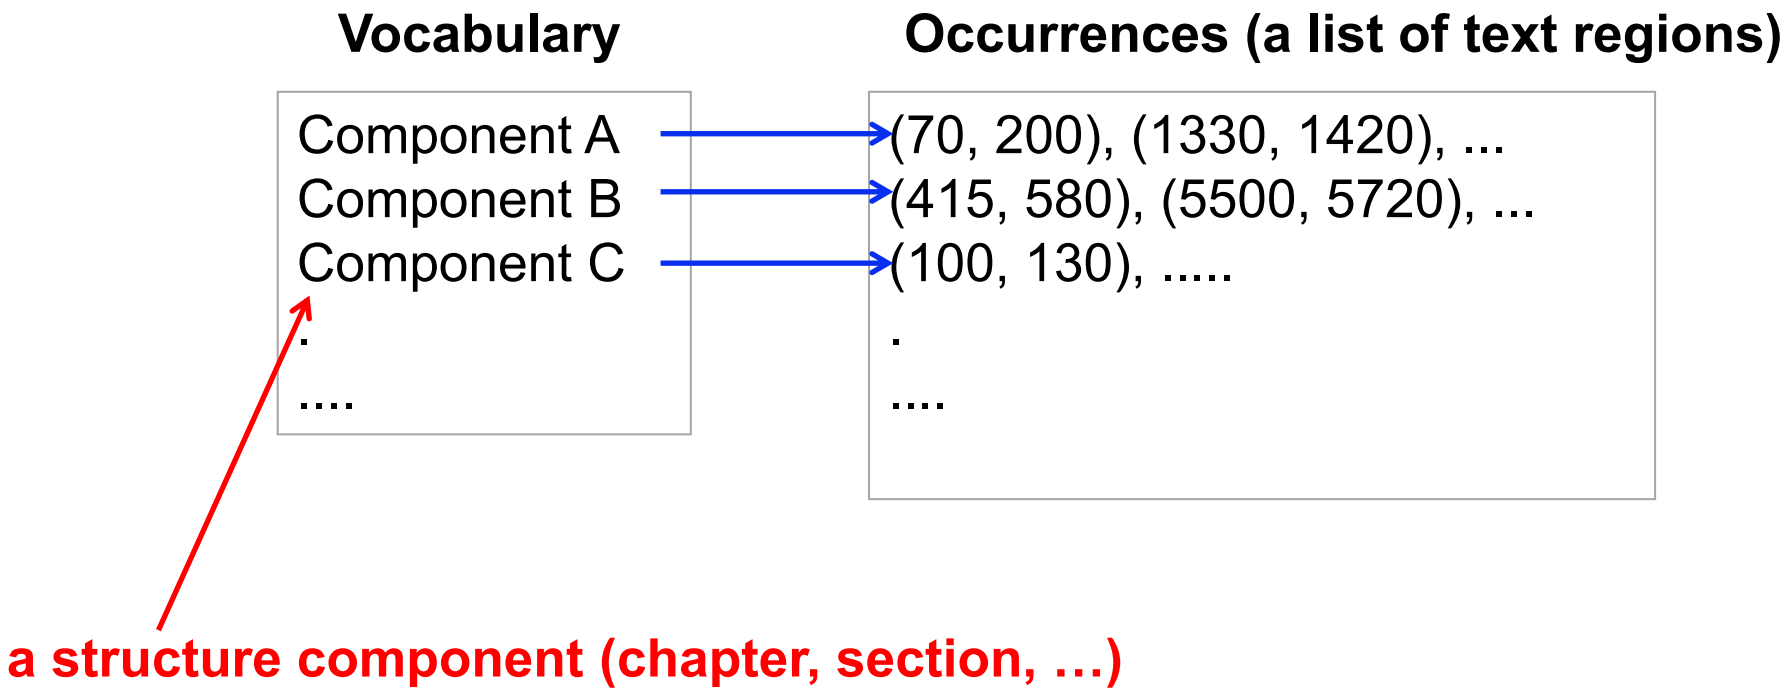

A inverted-file structure for non-overlapping lists

Conclusions

- The non-overlapping lists model is simple and allows efficient implementation
- But, types of queries that can be asked are limited "**Database in Chapter Name and Section Name**"
- Also, model does not include any provision for ranking the documents *by* ***degree of similarity*** to the query
- What does structural similarity mean?

Proximal Nodes

- Due to Navarro and Baeza-Yates, 1997
- Idea: define a strict **hierarchical index over the text**. This enrichs the previous model that used flat lists.
- **Multiple index hierarchies** might be defined
- Two distinct index hierarchies might refer to text regions that overlap

Definitions

- Each indexing structure is a strict hierarchy composed of
  - chapters
  - sections
  - subsections
  - paragraphs
  - lines
- Each of these components is called a ***node***
- To each node is associated a text region

Proximal Nodes

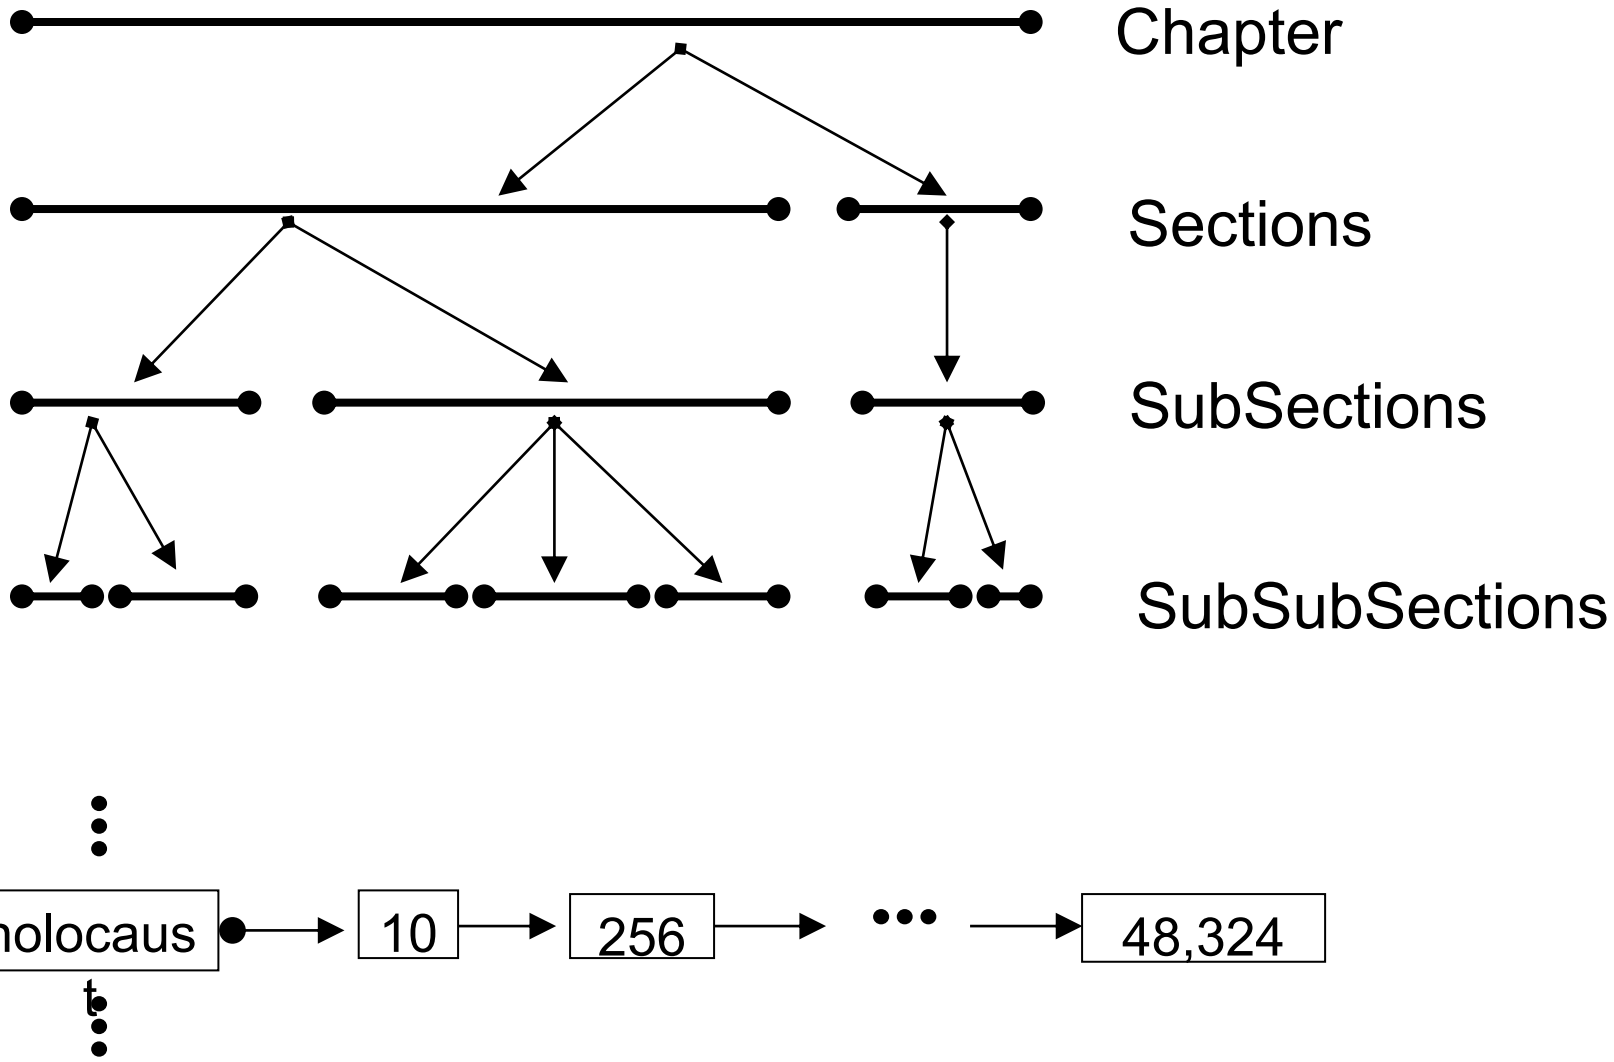

Proximal Nodes

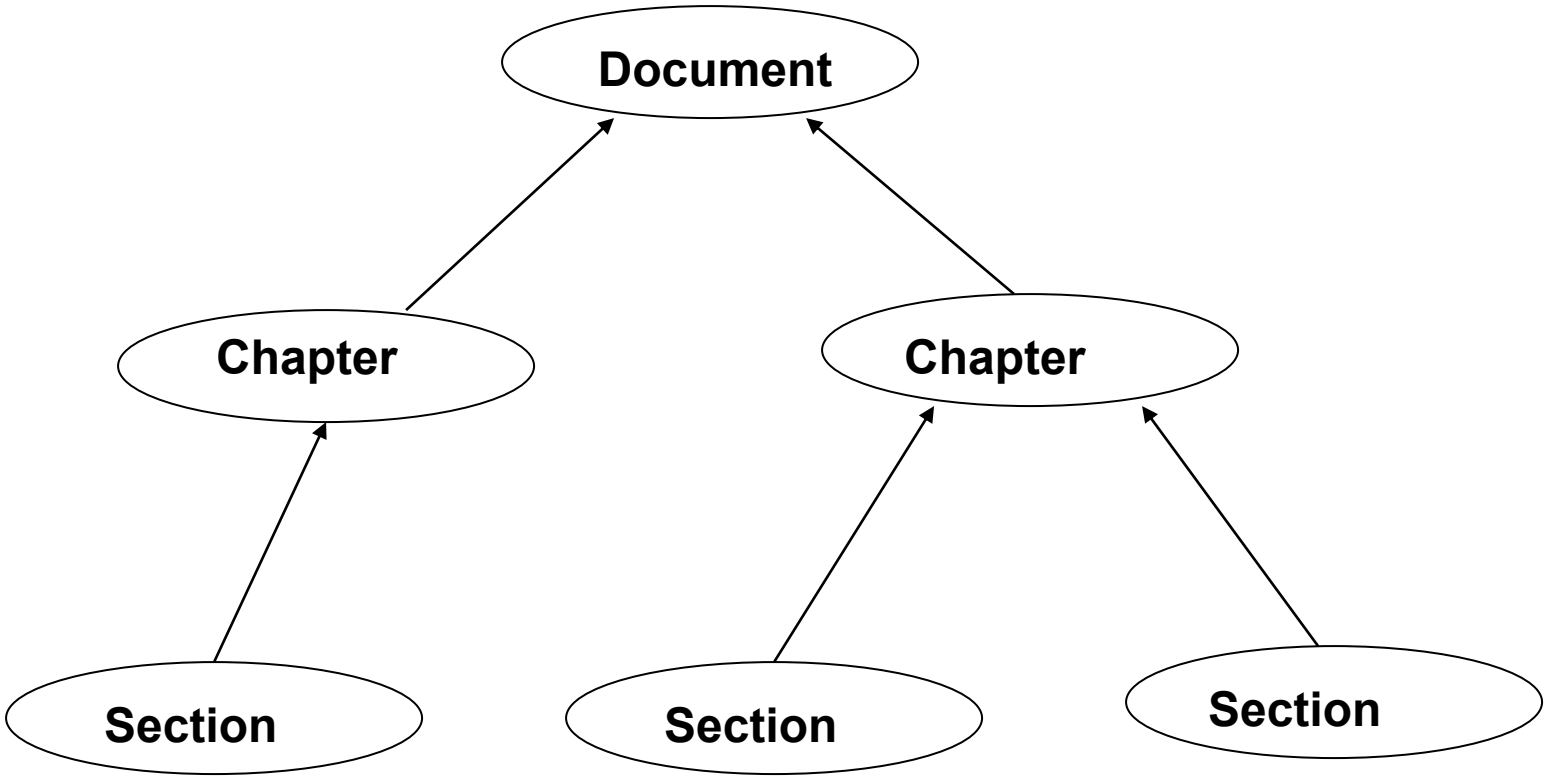

Proximal Nodes

- Key points:
  - In the hierarchical index, one node might be contained within another node
  - But, two nodes of a same hierarchy cannot overlap
  - The inverted list for keywords complements the hierarchical index
  - The implementation here is more complex than that for non-overlapping lists

Conclusions

- Model allows formulating queries that are more sophisticated than those allowed by non-overlapping lists
- To speed up query processing, nearby nodes are inspected
- Types of queries that can be asked are somewhat limited (**all nodes in the answer must come from a same index hierarchy!)**
- Model is a compromise between efficiency and expressiveness

Model for Browsing

- Flat Browsing
- Structure Guided Browsing
- The Hypertext Model

Flat Browsing

-Documents represented as dots in

- A two-dimensional plane
- A one-dimensional plane (list)

-User not know indicator,subject,page ...

Structure Guided Browsing

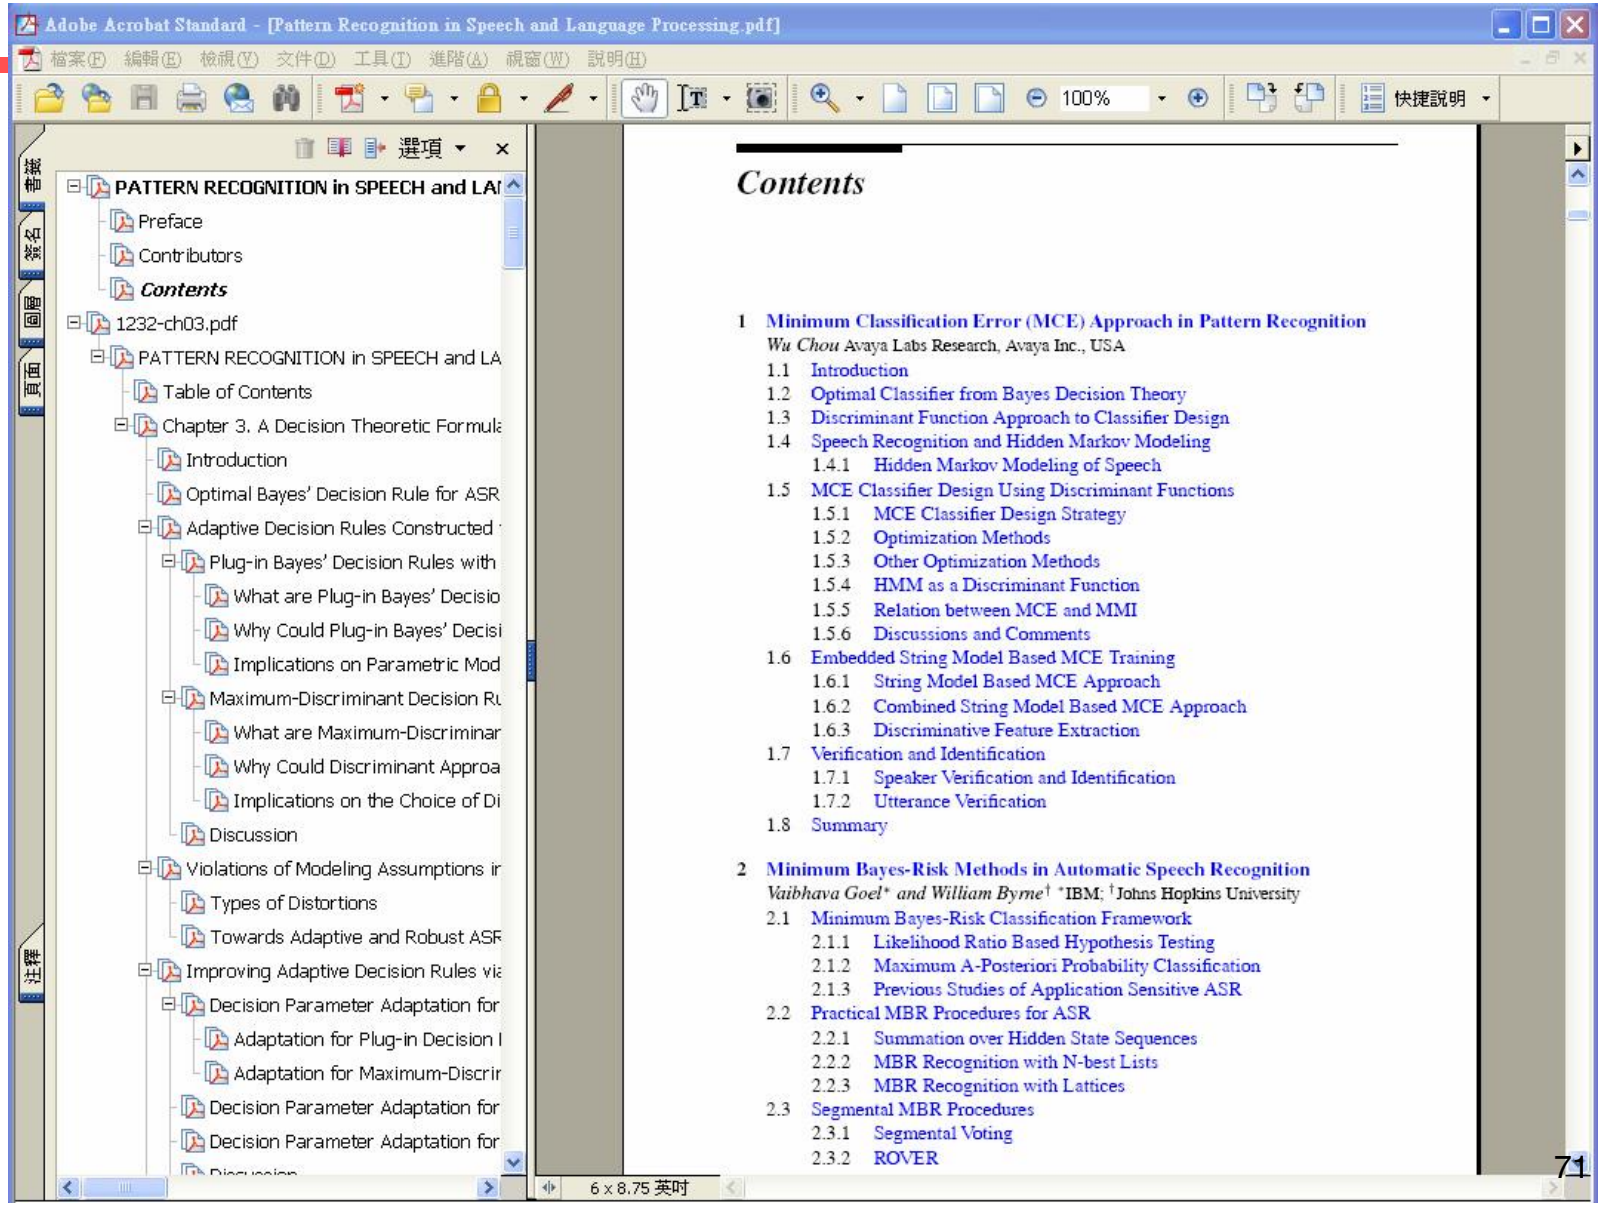

Hypertext browsing

Information Retrieval in Hypertext

Home | Hypertext | IR Issues | Auto Link Generation | My System | Bibliography

Navigation or browsing is effective for small hypertext systems. For large hypertext databases, information retrieval (IR) through queries becomes crucial, although some well-structured hypertext systems, such as Victorian Web, can be navigated smoothly even without the help of information retrieval. However, Information retrieval systems serve the purpose of finding data items that are relevant to the users query request. The World Wide Web, as the largest hypertext system, is a tool that has become very popular as a means to easily access information from other sites. It is almost impossible to explore such a huge collection of various hypertext documents. **Thus information retrieval plays an extremely critical role in hypertext systems.** Of course, conversely, I argue here **hyperlinks can greatly reinforce the usage of information retrieval systems**.

Conklin had suggested that search and query mechanisms can present information at a manageable level of complexity and detail [Conklin, 1987]. Halasz's view was that "*navigational access itself is not sufficient. Effective access to information stored in a hypermedia network requires query-based access to complement navigation.....search and query needs to be elevated to a primary access mechanism on par with navigation.*" [Halasz, 1988].

Information retrieval is a large research area, mostly concerned with finding information in textual material [Bärtschi85], [Salton89]. The simplest form of information retrieval is the full text search, which finds occurrences of words or phrases specified by the user, combined by boolean operators and weighting of words based on their statistical properties. When a hyperdocument is simply regarded as a text database (ignoring the links) this type of information retrieval is the same as for other textual databases, like dictionaries, encyclopedia, on-line library catalogs, etc.

Finding information is a three-step process:

1. **finding documents**: in a centralized hypertext this is no problem; but on the Internet (World Wide Web) it may be difficult to get access to all potentially interesting documents (because there are millions of them, distributed over the whole world).
2. **formulating queries**: the user needs to express exactly what kind of information (s)he is looking for.
3. **determining relevance**: the system must determine whether a document contains the information the user is looking for.

Traditional information retrieval research and development has concentrated on the second and third step. The distributed nature of the Internet, as well as the size of large hypertexts on CD-ROM, requires shifting the focus towards the first step.

When a text database is large, but centralized, special indexing mechanisms can be employed to speed up the search. For relatively static documents, a popular indexing mechanism is the use of inverted files. Recently a new indexing mechanism, called Glimpse is becoming popular, because it requires much less space overhead than inverted files and other indexing techniques.

Bruza [Bruza-90] proposed a two-level hypertext architecture for hyperdocuments, containing a hyperindex used for information retrieval. First the index term describing the required information would be searched, followed by a "beam down" operation to the hyperdocument itself, to evaluate the selected nodes from the hyperdocument. Bruza proposed measures to determine the effectiveness of index expressions in the hyperindex.

The result of a search may be either a pointer to the first match found, or a scored list of matches. Information retrieval is inherently uncertain: a very general query (like asking for one keyword) may yield too many answers, while a very specific query may result in no answers at all.

-Not fully understand, Random read, Nonsequence browse, Miscommunication for reader and writer

BM25 Model (Best Matching 25)

ความหมาย

เป็น Extended Probabilistic Model ที่สามารถใช้ได้กับเอกสารทั้งหมด จากเดิมที่ Probabilistic Model จะใช้ได้เมื่อมีการระบุเอกสารที่ถูกส่งออกมา และ Model นี้จะให้ความสำคัญกับน้ำหนักของ Keyword ในเอกสาร

สูตร

$$Sim_{bm25}(d_j, q) = \underbrace{\log \frac{(r_i + 0.5)/(R - r_i + 0.5)}{(n_i - r_i + 0.5)/(N - n_i - R + r_i + 0.5)}}_{A} \cdot \underbrace{\frac{f_i}{K_1((1-b) + b \cdot \frac{dl}{avdl}) + f_i}}_{B,C} \cdot \underbrace{\frac{(k_2 + 1) qf_i}{K_2 + qf_i}}_{D}$$

โดยที่
- d_j = เอกสารที่ j
- R = จำนวนเอกสารที่ตรงประเด็น
- N = จำนวนเอกสารทั้งหมด
- r_i = จำนวนเอกสารตรงประเด็นที่มี Keyword i
- n_i = จำนวนเอกสารทั้งหมดที่มี Keyword i

- f_i = ความถี่ของ Keyword i ในเอกสาร j
- dl = จำนวนคำของเอกสาร j
- $avdl$ = จำนวนคำเฉลี่ยของทุกเอกสาร
- qf_i = ความถี่ของ Keyword i ใน query
- b = ค่าคงที่ตาม TREC จะใช้ 0.75 $(0.5 < b < 0.8)$

- k_1 = ค่าคงที่ตาม TREC จะใช้ 1.25 $(1.2 < k_1 < 2)$
- k_2 = ค่าคงที่ โดยปกติอยู่ในช่วง 0 - 1,000

โดยมีกลุ่มตัวแปรที่ใช้ ดังนี้

(A) จำนวนเอกสารที่มี Keyword

$$\frac{\text{ความน่าจะเป็นที่เอกสารจะตรงประเด็น}}{\text{ความน่าจะเป็นที่เอกสารจะไม่ตรงประเด็น}}$$

ความน่าจะเป็นที่เอกสารมี Keyword แล้วตรงประเด็น / ความน่าจะเป็นที่เอกสารไม่มี Keyword แล้วตรงประเด็น

$$\frac{\frac{r_i + 0.5}{R + 0.5}}{\frac{R - r_i + 0.5}{R + 0.5}} \rightarrow \frac{r_i + 0.5}{R - r_i + 0.5}$$

ที่มี +0.5 เพราะป้องกันค่าเป็น 0

ความน่าจะเป็นที่เอกสารมี Keyword แล้วไม่ตรงประเด็น / ความน่าจะเป็นที่เอกสารไม่มี Keyword แล้วไม่ตรงประเด็น

$$\frac{\frac{n_i - r_i + 0.5}{N - R + 0.5}}{\frac{N - n_i - R + r_i + 0.5}{N - R + 0.5}} \rightarrow \frac{n_i - r_i + 0.5}{N - n_i - R + r_i + 0.5}$$

จะได้เป็น $\log \frac{(r_i + 0.5)/(R - r_i + 0.5)}{(n_i - r_i + 0.5)/(N - n_i - R + r_i + 0.5)}$ (log ใส่เพื่อไม่ให้ค่าต่างกันมากเกิน)

(B) ความถี่ของ Keyword ในแต่ละเอกสาร

มีการใส่ค่าคงที่เพื่อให้ค่า smooth จะใช้สูตร $\frac{f_i}{K_1((1-b) + b \cdot \frac{dl}{avdl}) + f_i}$

(C) ความยาวของเอกสาร "จำนวนคำ" หรือ Document length normalization

(D) ความถี่ของ Keyword ในแต่ Query

มีความสำคัญน้อยกว่า (B) ถ้าความถี่ = 1 ส่วนนี้จะมีค่าเท่ากับ 1 ซึ่งไม่มีผลกับสมการ

ข้อดี, ข้อเสีย/ข้อจำกัด

ข้อดี

- จัดลำดับละเอียดกว่า Probalistic Model
- สามารถใช้กับเอกสารทั้งหมดหรือเฉพาะเอกสารที่ถูกส่งออกมา

X - มีความเรียบง่ายและมีประสิทธิภาพ

ข้อเสีย/ข้อจำกัด

- รองรับ Query อย่างง่ายเท่านั้น ไม่พิจารณา Query เชิงความหมายและ Boolean Expression
- ไม่สนใจความสัมพันธ์ของ Keyword
- การRanking เปลี่ยนตามจำนวนเอกสารในระบบ

เพิ่มเติม ถ้า N, n_i ไม่ต่างกันมาก อาจทำให้ Ranking ผิดพลาดได้

วิธีแก้ : ปรับจำนวนเอกสารในระบบ

GVSM Model (Generalizes Vector Space Model)

ความหมาย

เป็น Model ที่ใช้หลักการเดียวกับ Vector Space Model (VSM) แต่จะให้ความสำคัญกับรูปแบบการปรากฏของ Keyword ว่าจะนำมาซึ่งความคล้ายหรือความต่างของเอกสาร ซึ่งแสดงถึงความสัมพันธ์ระหว่าง Keyword และมีผลต่อความแรงประเด็น

สูตร

- จะมีการจัดแปลน (m: minterm) ของเอกสาร โดยเอกสารที่มี Pattern เหมือนกันจะอยู่แปลนเดียวกัน
- ก่อนจัดแปลนต้องมีการคำนวณน้ำหนักของ Keyword ในแต่ละเอกสาร

  จาก $w_{ij} = tf_{ij} \cdot id_{ij}$

  โดยที่ w_{ij} = น้ำหนักของ Keyword ที่ i ใน เอกสารที่ j

  tf_{ij} = ความถี่ Keyword ในเอกสาร / ความถี่ Keyword สูงสุดในเอกสาร

  $idf_{ij} = \log$ จำนวนเอกสารทั้งหมด / จำนวนเอกสารที่มี Keyword

- สูตรคำนวณ K_i

$$K_i = \frac{\sum_{\forall r, g_i(m_r)} C_{i,r}\, m_r}{\sqrt{\sum_{\forall r, g_i(m_r)} C_{i,r}^2}}$$

เลือกแปลนที่มี Keyword ที่ i แล้วหา $C_{i,r}$ โดยคิดจากทุกเอกสารในแปลนนั้นๆ

ตัวส่วน → $\sqrt{\text{ผลรวม } C_{i,r}^2}$

โดยที่ $C_{i,r}$ = ผลรวม Keyword ที่ i ในแปลน R

- หาสมการของ d_j, q มาคิด $Sim(q, d_j)$

$$Sim(q, d_j) = \frac{\sum_r S_{d,r} \cdot S_{q,r}}{\sqrt{\sum_r S_{d,r}^2 \cdot \sum_r S_{q,r}^2}}$$

→ ตัวแปรเหมือนกันคูณกัน อย่าลืมนำเครื่องหมายมา!!

เพิ่มเติม ถ้าเอกสารอยู่ในแปลนเดียวกัน จะมี Ranking ติดกัน

ข้อดี, ข้อเสีย / ข้อจำกัด

ข้อดี

- จัดลำดับโดยคำถึงความสัมพันธ์ของ Keyword
- มีน้ำหนักของแต่ละ Keyword ในเอกสาร

ข้อเสีย / ข้อจำกัด

- ไม่พิจารณา Query ที่เป็น Boolean Expression